TB x-rAI Net 2.0: Evolução no Apoio ao Diagnóstico de Tuberculose em Imagens Radiológicas através de Rede Neural Convolucional

Isadora M.R. Cruz[1], Karina S. Machado[1]

[1]Centro de Ciências Computacionais (C3) – Universidade Federal do Rio Grande (FURG)
Rio Grande – RS – Brasil

isadoramataramoscruz@gmail.com, karinaecomp@gmail.com

Abstract. *Tuberculosis (TB) remains a public health challenge, for which chest X-ray is the most widely used screening examination for diagnosis, despite its inherent limitations. In this context, Convolutional Neural Networks (CNNs) emerge as valuable tools for a faster and more effective diagnosis. Thus, TB x-rAI Net 2.0 is proposed as an updated version of TB x-rAI, incorporating filter CLAHE and a larger dataset alongside previously employed techniques. The results show an accuracy of 89%, an AUC of 92%, a precision of 93%, a sensitivity of 88% and an F1-Score of 90%.*

Resumo. *A Tuberculose (TB) permanece como um desafio de saúde pública, no qual o raio-x torácico é o exame de triagem mais utilizado para esse diagnóstico, apesar das suas particularidades inerentes. A partir desse cenário, as Redes Neurais Convolucionais (CNNs) surgem como aliadas para um diagnóstico mais rápido e eficaz. Assim, propõe-se a TB x-rAI Net 2.0, um modelo atualizado da TB x-rAI, aplicando filtro CLAHE e uma maior base de dados combinadas às técnicas anteriores. Os resultados mostram uma acurácia de 89%, AUC de 92%, precisão de 93%, sensibilidade de 88% e F1-Score de 90%.*

1. Introdução

A Tuberculose (TB) permanece sendo um desafio na saúde pública. Para o rastreio e diagnóstico da doença, a radiografia de tórax constitui uma importante ferramenta [Jaeger et al. 2013]. Apesar da sua usabilidade na área médica, a avaliação desse exame requer análises minuciosas, devido à sutileza dos padrões radiológicos [WHO 2016]. Nesse contexto, as Redes Neurais Convolucionais (CNNs) surgem como aliadas na identificação de padrões complexos para grandes conjuntos de dados, auxiliando profissionais da saúde a tomarem decisões mais precisas e rápidas.

Diante disso, este trabalho propõe um modelo de CNN denominado TB x-rAI Net 2.0, apresentando e comparando as diferenças para o TB x-rAI [Cruz et al. 2026]. A nova versão combina as técnicas já utilizadas a um novo filtro de pré-processamento *CLAHE* (do inglês, *Contrast Limited Adaptive Histogram Equalization*) e um maior conjunto de dados de treinamento.

2. Materiais e métodos

O modelo de [Pasa et al. 2019] desenvolve uma CNN simples e eficiente comparada aos métodos tradicionais aplicando *saliency maps* e *grad-CAMs*, na visualização de lesões sugestivas de TB em radiografias, utilizando imagens de três *datasets* públicos, obtendo uma acurácia de 86% e AUC de 92%. O método de [Sun et al. 2024], propõe um *framework* de *ensemble deep learning* para o diagnóstico e subcategorização clínica da

Tuberculose utilizando radiografias de tórax, combinadas com *grad-CAMs*. A base de dados usa três *datasets*, obtendo uma acurácia de 100% no diagnóstico geral de TB.

O método proposto para a realização deste estudo concentra-se na melhora do modelo TB x-rAI [Cruz et al. 2026]. Em vista disso, por meio da aplicação do filtro *CLAHE* e inserção de uma base de dados mais ampla, procura-se investigar o impacto dessas técnicas, de maneira isolada e conjunta com as técnicas anteriores, para o desempenho do TB x-rAI Net 2.0.

2.1. Modelo de Rede Neural Convolucional - TB X-rAI Net 2.0

A Figura 1 resume a metodologia proposta para a CNN TB x-rAI 2.0. A base de dados é proveniente de quatro *datasets*: 278 radiografias de [Chauhan 2014], 304 de [Frapa 2021], 662 de [Mengzhang 2024] e 138 de [Raddar 2020]. Após a remoção de 4 radiografias duplicadas de [Frapa 2021], totalizou 1378 imagens. No pré-processamento, as imagens passam por redimensionamento para 256x256 *pixels*, conversão para escala de cinza e utilizam o filtro *CLAHE*, para realçar o contraste e diminuir o ruído, permitindo destacar regiões importantes para o diagnóstico da TB.

A arquitetura possui cinco blocos convolucionais, cada um com duas convoluções 3x3, normalização em lote, *ReLU*, conexão residual, mecanismo SE, *max-pooling*, camada *GAP*, *dropout* e ativação *Sigmoid*. O *ensemble* combina três métodos configurados com filtros iniciais (32, 64 e 128) e taxas de *dropout* distintas (0,3, 0,4 e 0,5). Para amenizar o desbalanceamento entre as classes (823 imagens TB-positivas e 559 TB-negativas), empregou-se *Binary Focal Cross Entropy* juntamente com pesos de classe inversamente proporcionais à frequência das amostras.

Os dados foram divididos em 70/15/15 a nível de paciente: 965 imagens de treino, 206 de validação e 207 de teste.. No treinamento usou-se o aumento de dados em tempo real com *ImageDataGenerator*, da biblioteca *Keras* [Chollet et al. 2015]. Os três modelos do *ensemble* foram treinados por até 50 épocas com *Early Stopping*, *batch size* de 16, otimizador *Adam*, taxa de aprendizado de 10^{-4} e *Reduce LR On Plateau*, na redução do *overfitting*.

Na validação, foram avaliadas a acurácia, AUC, sensibilidade, precisão e função de perda, usando as probabilidades da ativação *Sigmoid* no cálculo da AUC, definindo os pesos do *ensemble*. O *threshold* foi estabelecido pelo índice de Youden na curva ROC e sensibilidade, sendo empregado no teste. No teste, as predições do *ensemble* foram integradas por média ponderada, e o threshold definiu a classe final da imagem. Ao fim, uma imagem do conjunto de teste foi usada na geração de um *grad-CAM*, na interpretação das regiões que contribuíram para a decisão do modelo.

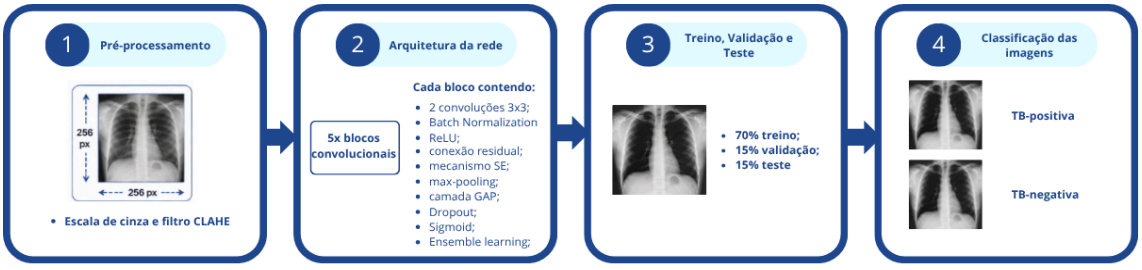


Figura 1. Funcionamento da CNN proposta.

3. Resultados Experimentais

O treinamento do modelo foi realizado no ambiente virtual do *Google Colab*, utilizando uma GPU Nvidia T4 Tensor Core. A CNN foi treinada a partir de um *script Python*, com o uso das bibliotecas *TensorFlow*, *Keras*, *NumPy*, *Matplotlib* e *Scikit-Learn*.

Os resultados apresentados na Tabela 1 demonstram o papel das novas técnicas na melhora das predições de TB. Observa-se que a TB x-rAI Net 2.0 possui resultados consistentes frente à arquitetura de [Cruz et al. 2026]. Já em [Pasa et al. 2019], os resultados mostraram-se robustos, apesar do distinto contexto experimental entre ambos os estudos. Quanto a [Sun et al. 2024], o desempenho foi inferior, principalmente pelo uso da teoria da dimensão *VC*, para o ajuste a conjuntos de dados de diferentes tamanhos, complexidades e no combate ao *overfitting* da rede.

Tabela 1. Comparação dos resultados obtidos entre diferentes estudos.

Estudo	Acc(%)	Auc(%)	Prec. (%)	Sens. (%)	F1-Score(%)
[Cruz et al. 2026]	84	89	95	79	86
[Pasa et al. 2019]	86	92	-	-	-
[Sun et al. 2024]	100	100	-	100	100
Modelo proposto	**89**	**92**	**93**	**88**	**90**

Para verificar a contribuição de cada uma das estratégias adotadas foi realizado um estudo de ablação, removendo, de maneira isolada, os componentes citados abaixo. Ressalta-se que no teste de ablação sem o *ensemble*, foi utilizada a configuração com *dropout* de 0,4 e filtro inicial de 64.

Tabela 2. Comparação dos resultados obtidos em diferentes testes de ablação.

Teste de ablação	Acc(%)	Auc(%)	Prec.(%)	Sens.(%)	F1-Score(%)
Sem mecanismo SE	82	87	94	76	84
Sem ensemble learning	79	85	97	69	80
Sem data augmentation	85	91	97	79	87
Sem CLAHE	84	89	95	79	86
Modelo completo	**89**	**92**	**93**	**88**	**90**

De acordo com o estudo de ablação, nota-se que a remoção individual de cada técnica reduziu o desempenho do modelo completo. Cabe destacar o impacto referente a remoção do *ensemble*, mecanismo SE e *CLAHE,* o qual diminuiu a acurácia e a sensibilidade. Embora a retirada das estratégias citadas tenham exibido uma precisão superior ao modelo completo, o uso combinado dessas elevou os valores encontrados nas demais medidas.

Cabe ressaltar algumas limitações da TB x-rAI Net 2.0 envolvendo o uso de uma única partição de dados, uma validação apenas interna, sem o uso de um conjunto de teste externo independente e a aplicação de um *grad-CAM* único nos testes, sendo necessária a análise de múltiplos casos.

4. Conclusão

Este estudo apresentou uma CNN Residual SE desenvolvida para auxiliar no apoio ao diagnóstico da TB. Os resultados obtidos mostraram o potencial do método proposto, destacando-se as contribuições do *ensemble learning*, mecanismo *SE* e *CLAHE* nas predições da Tuberculose. Como trabalhos futuros, propõe-se melhorar as métricas de desempenho, realizar a validação da CNN com especialistas da área da saúde e adicionar os aspectos identificados como limitações do estudo.

5. Agradecimentos

O presente trabalho foi desenvolvido com apoio da CAPES, do CNPq processo número 406015/2025-2, da FAPERGS processos 25/2551-0002578-8, 22/2551-0000385-0 e 22/2551-0000390-7.

Referências

Chauhan, A., Chauhan, D., Rout, C. (2014). Role of Gist and PHOG Features in Computer-Aided Diagnosis of Tuberculosis without Segmentation. *National Library of Medicine*, 9(11).

Chollet, F. et al. (2015). Keras, https://keras.io. Acesso em: Janeiro de 2026.

Cruz, I., M., R., Machado, K., S. (2026). TB x-rAI: Apoio ao Diagnóstico de Tuberculose em Imagens Radiológicas através de Rede Neural Convolucional e Aplicação Web. In *Anais estendidos do XXVI Simpósio Brasileiro de Computação Aplicada à Saúde*, pages 323-328. SBC.

Frapa (2021). A convolutional neural network for tuberculosis diagnosis from frontal chest x-rays, https://www.github.com/frapa/tbcnn. Acesso em: Janeiro de 2026.

Jaeger, S., Karargyris, A., Candemir, S., Siegelman, J., Folio, L., Antani, S., and Thoma, G. (2013). Automatic screening for tuberculosis in chest radiographs: a survey. *Quantitative Imaging in Medicine and Surgery*, 3(2), pages 89-99.

Mengzhang, L. (2024). Awesome-Medical-Dataset, https://www.github.com/openmedlab/Awesome-Medical-Dataset/blob/main/resources/Shenzhen_chest_X-ray.md. Acesso em: Janeiro de 2026.

Pasa, F., Golkov, V., Pfeiffer, F., Cremers, D., and Pfeiffer, D. (2019). Efficient deep network architectures for fast chest x-ray tuberculosis screening and visualization. *Scientific reports*, 9(1):6268.

Raddar (2020). Tuberculosis Chest x-rays (Montgomery), https://www.kaggle.com/datasets/raddar/tuberculosis-chest-xrays-montgomery. Acesso em: Janeiro de 2026.

Sun, X., Xing, Z., Wan, Z., Ding, W., Wang, L., Zhong, L., Zhou, X., Gong, X., Li, Y., and Zhang, X. (2024). A robust ensemble deep learning framework for accurate diagnoses of tuberculosis from chest radiographs. *Frontiers in Medicine*, v. 11, 1391184.

World Health Organization (2016). *Chest radiography in tuberculosis detection: summary of current WHO recommendations and guidance on programmatic approaches*. World Health Organization.